


Обнаружение аномалий

Виктор Китов

v.v.kitov@yandex.ru



Аномалии (выбросы)

- Аномалия (выброс, outlier) - объект, нетипичный для общего распределения объектов.
- Применения обнаружения аномалий
 - очистка данных (убрать ошибочные наблюдения)
 - обнаружение нетипичных объектов:
 - мошеннические финансовые транзакции
 - хакерские атаки в сети
 - мониторинг исправности устройств

Методы обнаружения аномалий

- Виды постановок задач:
 - **Детекция новизны (novelty detection):** обучающая выборка не содержит аномалий.
 - **Детекция выбросов (outlier detection):** обучающая выборка содержит аномалии.
- Методы оценивают степень нетипичности:

$$x - \text{выброс} \iff \text{outlierness}(x) > \text{threshold}$$

- Это задача обучения без учителя
 - если с учителем, то это классификация несбалансированных классов
- Оценка - по размеченной валидации, используя ROC, AUC.
 - но не используем для обучения-выбросов мало, переобучимся


Содержание

- 1 Статистическое обнаружение аномалий
- 2 Обнаружение аномалий по расстоянию
- 3 Одноклассовый метод опорных векторов
- 4 Изолирующий лес

Статистическое обнаружение аномалий


- Выбросы - точки с $p(x) < threshold$.
- Предположим $p(x) \sim \mathcal{N}(x|\mu, \Sigma) \propto e^{-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)}$.
- После получения $\hat{\mu}, \hat{\Sigma}$ устойчивым к выбросам способом найдем расстояние Махаланобиса:

$$outlierness(x) = \sqrt{(x - \hat{\mu})^T \hat{\Sigma}^{-1}(x - \hat{\mu})}$$




Статистическое обнаружение аномалий

- Выбросы не обязательно на границе распределений:



(a) Symmetric distribution



(b) Asymmetric distribution


- $p(x)$ можно оценить параметрически, смесью или ядерной оценкой плотности (KDE)
 - лучше не включать x в оценку, особенно для KDE.

Содержание

- 1 Статистическое обнаружение аномалий
- 2 Обнаружение аномалий по расстоянию
- 3 Одноклассовый метод опорных векторов
- 4 Изолирующий лес

Обнаружение аномалий по расстоянию

простой способ: $x\text{-outlier} \iff d_K(x) > threshold$



- выброс А либо пропущен, либо все точки разреженного кластера - выбросы.
- Local outlier factor (LOF) приспособляется к изменяемой плотности.

Метод local outlier factor

- Идея: смотреть на относительное расстояние:

$$outlierness(x) = \frac{\rho(x, x_{NN_K(x)})}{\rho(x_{NN_K(x)}, x_{NN_K(x_{NN_K(x)})})}$$

где $NN_K(x)$ -индекс K -го ближайшего соседа x .

Метод local outlier factor

- Идея: смотреть на относительное расстояние:

$$outlierness(x) = \frac{\rho(x, x_{NN_K(x)})}{\rho(x_{NN_K(x)}, x_{NN_K(x_{NN_K(x)})})}$$

где $NN_K(x)$ -индекс K -го ближайшего соседа x .


- Метод LOF (сглаженный вариант)

$$outlierness(x) = \frac{1}{K} \sum_{i \in NN_K(x)} \frac{AR_K(x)}{AR_K(x_i)}$$

где $AR_K(x)$ - оценка локальной плотности вокруг x :

$$AR_K(x) = \frac{1}{K} \sum_{i \in NN_K(x)} \rho(x, x_i)$$

Учет локального распределения точек



- У учетом локального распределения выброс м. быть не самым далеким объектом.
- Подходы, учитывающие локальное распределение:
 - смесь Гауссиан, выброс-точка с малым $p(x)$ либо принадлежащая компоненте с большим Σ .
 - метод локального кластера (local cluster)
 - метод локальной окрестности (local neighborhood)

Метод локального кластера

- 1 Кластеризуем точки на K кластеров:
- 2 Для каждого кластера находим μ_k и Σ_k .
- 3 Для объекта x :
 - 1 находим ближайший кластер:

$$\hat{c} = \arg \min_c \sqrt{(x - \mu_c)^T \Sigma_c^{-1} (x - \mu_c)}$$

- 2 степень нетипичности:

$$outlierness(x) = \sqrt{(x - \mu_{\hat{c}})^T \Sigma_{\hat{c}}^{-1} (x - \mu_{\hat{c}})}$$

Метод локальной окрестности

- ❶ Инициализируем $L_K(x) = \{x\}$
- ❷ Для $k = 1, 2, \dots, K$:
 - ❶ $x_k = \arg \min_z \rho(z, L_K(x))$
 - ❷ $L_K(x) := L_K(x) \cup \{x_k\}$
- ❸ Исключим x : $L_K(x) := L_K(x) \setminus \{x\}$
- ❹ Используя $L_K(x)$ рассчитаем $\mu(x)$ и $\Sigma(x)$
- ❺ Степень нетипичности:

$$outlierness(x) = \sqrt{(x - \mu(x))^T \Sigma(x)^{-1} (x - \mu(x))}$$

Комментарий: вычислительно сложнее м-да локального кластера, зато лучше таргетирует распределение вокруг x .

Содержание

- 1 Статистическое обнаружение аномалий
- 2 Обнаружение аномалий по расстоянию
- 3 Одноклассовый метод опорных векторов
- 4 Изолирующий лес

Одноклассовый метод опорных векторов

Найдем подпирающую границу данных $\langle w, x_n \rangle + w_0 \geq \rho$ с макс. ρ :

$$\begin{cases} \frac{1}{2} \|w\|^2 - \rho \rightarrow \min_{w, w_0, \rho}, \\ \langle w, x_n \rangle + w_0 \geq \rho \end{cases} \quad n = \overline{1, N}$$

Одноклассовый метод опорных векторов

Найдем подпирающую границу данных $\langle w, x_n \rangle + w_0 \geq \rho$ с макс. ρ :

$$\begin{cases} \frac{1}{2} \|w\|^2 - \rho \rightarrow \min_{w, w_0, \rho}, \\ \langle w, x_n \rangle + w_0 \geq \rho \end{cases} \quad n = \overline{1, N}$$

Одноклассовый метод опорных векторов (one-class SVM) оставляет "нарушителей", внося штраф $\xi_n \geq 0$:


$$\begin{cases} \frac{1}{2} \|w\|^2 + \frac{1}{\nu N} \sum_{n=1}^N \xi_n - \rho \rightarrow \min_{w, \rho, \xi_1, \dots, \xi_N} \\ \langle w, x_i \rangle + w_0 \geq \rho - \xi_n, \quad n = \overline{1, N}. \\ \xi_n \geq 0, \quad n = \overline{1, N}. \end{cases}$$

$\langle w, x_i \rangle + w_0 < \rho \Leftrightarrow x_i - \text{выброс}, \nu \downarrow \Rightarrow \# \text{выбросов} \downarrow$, доля выбросов в выборке $\rightarrow \nu$ при $N \rightarrow \infty$

$$\text{outlierness}(x) = \rho - \langle w, x \rangle + w_0$$


Интуиция

Выбросы - объекты, слишком близкие к началу координат



Ядерное обобщение с RBF ядром

Одноклассовый SVM с RBF ядром ($\sigma \uparrow$)



Содержание

- 1 Статистическое обнаружение аномалий
- 2 Обнаружение аномалий по расстоянию
- 3 Одноклассовый метод опорных векторов
- 4 **Изолирующий лес**

Изолирующий лес

- Алгоритм построения изолирующего дерева:

инициализировать корень со всеми наблюдениями

пока существуют узлы с ≥ 2 несовпадающими наблюдениями:

 выбрать такой узел

 выбрать случайный неконстантный признак f

 выбрать случайный порог $t \in [f_{min}, f_{max})$

 разбить узел на 2 подузла по правилу $f \leq t$

Изолирующий лес

- Алгоритм построения изолирующего дерева:

инициализировать корень со всеми наблюдениями

пока существуют узлы с ≥ 2 несовпадающими наблюдениями:

 выбрать такой узел

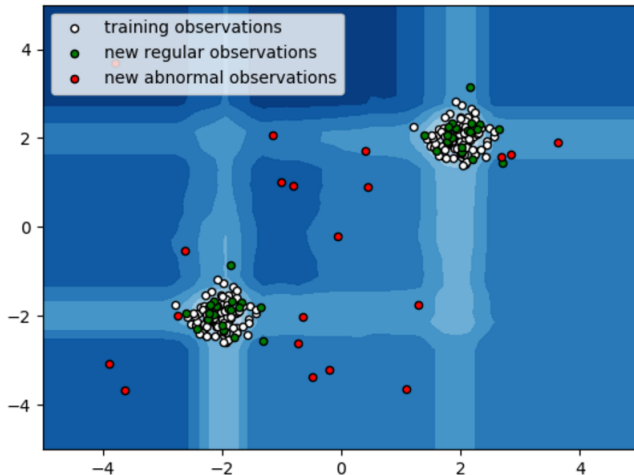
 выбрать случайный неконстантный признак f

 выбрать случайный порог $t \in [f_{min}, f_{max})$

 разбить узел на 2 подузла по правилу $f \leq t$

- Типичность объекта \approx глубина листа с этим объектом
 - выбросы легче отделить
 - показатель слишком зависит от дерева
- Изолирующий лес (isolation forest) - ансамбль M независимых изолирующих деревьев.
 - типичность объекта = средняя глубина соотв. листа по деревьям.
 - нетипичность = - типичность.

Пример работы изолирующего леса



Заключение

- Детекция выбросов - задача обучения без учителя
 - с учителем - классификация несбалансированных классов
- Важно адаптировать метод к
 - изменяющейся плотности данных
 - локальному распределению данных
- Оценка - по размеченной валидации, используя ROC, AUC.
- Подходы:
 - основанные на плотности $p_{\theta}(x) < threshold$, θ -робастная оценка.
 - основанные на расстоянии
 - Local outlier factor (LOF)
 - метод локальных центроидов
 - метод локальных окрестностей
 - Линейный: одноклассовый метод опорных векторов + ядерное обобщение
 - Правильный: изолирующий лес

Сравнение методов

Сравнение методов (sklearn)

