

## Сингулярное разложение

Виктор Китов

[v.v.kitov@yandex.ru](mailto:v.v.kitov@yandex.ru)

$$\begin{bmatrix} \bullet & \bullet & \bullet & \bullet & \bullet \\ \bullet & \bullet & \bullet & \bullet & \bullet \\ \bullet & \bullet & \bullet & \bullet & \bullet \\ \bullet & \bullet & \bullet & \bullet & \bullet \end{bmatrix} = \begin{bmatrix} \bullet & \color{red}\bullet & \bullet \\ \bullet & \color{red}\bullet & \bullet \\ \bullet & \color{red}\bullet & \bullet \\ \bullet & \color{red}\bullet & \bullet \end{bmatrix} \begin{bmatrix} \bullet & & & & \\ & \color{blue}\bullet & & & \\ & & \bullet & & \\ & & & \bullet & \\ & & & & \bullet \end{bmatrix} \begin{bmatrix} \bullet & \bullet & \bullet & \bullet & \bullet \\ \bullet & \bullet & \bullet & \bullet & \bullet \\ \color{green}\bullet & \color{green}\bullet & \color{green}\bullet & \color{green}\bullet & \color{green}\bullet \\ \bullet & \bullet & \bullet & \bullet & \bullet \\ \bullet & \bullet & \bullet & \bullet & \bullet \end{bmatrix}$$

# Содержание

- 1 Определение сингулярного разложения
- 2 Сокращенное сингулярное разложение
- 3 Применения сингулярного разложения
- 4 Простейшая рекомендательная система

## Сингулярное разложение

Сингулярное разложение (singular value decomposition, SVD):

Каждая матрица  $X \in \mathbb{R}^{N \times D}$ ,  $\text{rank } X = R$ , может быть разложена:

$$X = U \Sigma V^T$$

где


- $U \in \mathbb{R}^{N \times R}$ ,  $\Sigma \in \mathbb{R}^{R \times R}$ ,  $V^T \in \mathbb{R}^{R \times D}$
- $\Sigma = \text{diag}\{\sigma_1, \sigma_2, \dots, \sigma_R\}$ ,  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_R \geq 0$
- $U^T U = I$ ,  $V^T V = I$ ,  $I \in \mathbb{R}^{R \times R}$  - единичная матрица.

Эквивалентно:

$$X = \sum_{i=1}^R u_i \sigma_i v_i^T$$

где  $u_i$  -  $i$ -ая колонка  $U$  and  $v_i^T$  -  $i$ -ая строка  $V^T$ .

## Интерпретация сингулярного разложения



- Столбцы  $U$  - ортонормированный базис столбцов  $X$
- Строки  $V^T$  - ортонормированный базис строк  $X$
- $\Sigma$  - важности базисных векторов.

SVD дает компактное представление низкоранговой матрицы.

## Столбцы $V$ = главные компоненты $X$

$$X^T X = (U \Sigma V^T)^T U \Sigma V^T = (V \Sigma U^T) U \Sigma V^T = V \Sigma^2 V^T$$

Домножая на  $V$ , получим<sup>1</sup>

$$X^T X V = V \Sigma^2 V^T V = V \Sigma^2 \quad (1)$$

$V$  состоит из СВ  $X^T X$ , отвечающих СЗ  $\sigma_1^2, \sigma_2^2, \dots, \sigma_R^2$  - это  $R$  главных компонент.

$U$  - коэффициенты разложения объектов-строк  $X$  по главным компонентам.

---

<sup>1</sup>Сингулярные значения  $X$  - корень из СЗ  $X^T X$ , равные  $\sigma_1, \dots, \sigma_R$ .

## Нахождение $U$

$$XX^T = U\Sigma V^T (U\Sigma V^T)^T = U\Sigma V^T V \Sigma U^T = U\Sigma^2 U^T$$

Домножая справа на  $U$ , получим

$$XX^T U = U\Sigma^2 U^T U = U\Sigma^2.$$

$U$  состоит из СВ  $XX^T$ , отвечающих СВ  $\sigma_1^2, \sigma_2^2, \dots, \sigma_R^2$ .

## SVD: существование & единственность

### Теорема 1

*Для  $\forall X \in \mathbb{R}^{N \times D}$  сингулярное разложение существует.*

### Теорема 2

*Сингулярное разложение единственно с точностью до знака  $\Leftrightarrow X^T X \in \mathbb{R}^{D \times D}$  содержит  $D$  уникальных СВ.*


*С точностью до знака означает, что мы всегда можем одновременно поменять знаки  $u_i$  и  $v_i^T$  для  $\forall i = 1, 2, \dots, R$ .*

# Содержание

- 1 Определение сингулярного разложения
- 2 Сокращенное сингулярное разложение
- 3 Применения сингулярного разложения
- 4 Простейшая рекомендательная система



# Сокращенное сингулярное разложение



Сокращенное сингулярное разложение порядка  $K$  (truncated SVD):


убрать наименее важные столбцы  $U$  и строки  $V^T$ .

- Важность измеряется  $\sigma_1, \sigma_2, \dots, \sigma_R$ .

$$\text{diag}\{\sigma_1, \sigma_2, \dots, \sigma_K, \sigma_{K+1}, \dots, \sigma_R\} \longrightarrow \text{diag}\{\sigma_1, \sigma_2, \dots, \sigma_K, 0, 0, \dots, 0\}$$

$$X = \sum_{i=1}^R u_i \sigma_i v_i^T \approx \sum_{i=1}^K u_i \sigma_i v_i^T$$

# Сокращенное сингулярное разложение



Упрощение до ранга  $K \leq R$ :

$$X_K = U_K \Sigma_K V_K \approx X$$

$$\Sigma = \text{diag}\{\sigma_1, \sigma_2, \dots, \sigma_K, \sigma_{K+1}, \dots, \sigma_R\} \longrightarrow \text{diag}\{\sigma_1, \sigma_2, \dots, \sigma_K\} = \Sigma_K$$

$$U = [u_1, u_2, \dots, u_K, u_{K+1}, \dots, u_R] \longrightarrow [u_1, u_2, \dots, u_K] = U_K$$

$$V = [v_1, v_2, \dots, v_K, v_{K+1}, \dots, v_R] \longrightarrow [v_1, v_2, \dots, v_K] = V_K$$

## Свойства сокращенного сингулярного разложения

### Норма Фробениуса для матриц

$$\|X\|_F^2 = \sum_{n=1}^N \sum_{d=1}^D x_{nd}^2$$

- Для матрицы  $X$  и её аппроксимации  $\hat{X}$  можем измерить

$$\text{ошибка аппроксимации} = \|\hat{X} - X\|_F^2$$

### Теорема 3

Пусть  $X \in \mathbb{R}^{N \times D}$  аппроксимируется  $\hat{X}_K = U_K \Sigma_K V_K$ . Тогда:

- 1  $\text{rank } X_K = K$ .
- 2  $X_K = \arg \min_{B: \text{rank } B \leq K} \|X - B\|_F^2$

## Выбор порядка аппроксимации $K$

### Теорема 4

Для  $\forall$  матрицы  $X$  и её разложения  $X = U\Sigma V^T$ ,  
 $\Sigma = \text{diag}\{\sigma_1, \dots, \sigma_R\}$ :

$$\|X\|_F^2 = \sum_{i=1}^R \sigma_i^2$$

- Пусть  $X = U\Sigma V^T$ ,  $\Sigma = \text{diag}\{\sigma_1, \dots, \sigma_R\}$
- Аппроксимация  $\hat{X}_K = U\Sigma_K V^T$ ,  
 $\Sigma_K = \text{diag}\{\sigma_1, \dots, \sigma_K, 0, 0, \dots, 0\}$ .
- Ошибка аппроксимации  $X - \hat{X}_K = U\tilde{\Sigma} V^T$ , где  
 $\tilde{\Sigma} = \text{diag}\{0, 0, \dots, \sigma_{K+1}, \dots, \sigma_R\}$ , поэтому

$$\|X - \hat{X}_K\|_F^2 = \sum_{i=K+1}^R \sigma_i^2$$

## Выбор порядка аппроксимации $K$


Используя теорему 4, выберем  $K$ , дающую относительную ошибку меньше порога:

$$K = \arg \min_K \left\{ \frac{\|X - \hat{X}_K\|_F^2}{\|X\|_F^2} = \frac{\sum_{i=K+1}^R \sigma_i^2}{\sum_{i=1}^R \sigma_i^2} < threshold \right\}$$

# Содержание

- 1 Определение сингулярного разложения
- 2 Сокращенное сингулярное разложение
- 3 Применения сингулярного разложения**
- 4 Простейшая рекомендательная система

# Снижение размерности



- строки  $U$  дают компактное представление объектов  $X$ .
- $x_n \in \mathbb{R}^D \longrightarrow u_n \in \mathbb{R}^K, \quad K \leq D$ .

## Экономия памяти

Рассчитайте стоимость хранения  $X \in \mathbb{R}^{N \times D}$ , предполагая  $N \geq D$ :

представление $X$	требования по памяти
исходная $X$	?
полностью сингулярно разложенная $X$	?
сокращенно синг. разложенная ранга $K$	?



## Вычислительные затраты

- Умножение  $Xq$ 
  - $X$  - нормализованное представление документов
  - $q$  - нормализованный поисковый запрос

представление $X$	сложность $Xq$
исходная $X$	?
полностью сингулярно разложенная $X$	?
сокращенно синг. разложенная ранга $K$	?

## Нахождение похожих объектов и похожих признаков

- Похожие объекты имеют похожие признаки.
- Похожие признаки встречаются в объектах.
- Пример: обработка текстов.
  - сингулярное разложение дает высокоуровневое семантическое представление документов
  - можем сравнивать документы на семантическом уровне
    - синонимы объединяются
  - можем сравнивать слова

## Содержание

- 1 Определение сингулярного разложения
- 2 Сокращенное сингулярное разложение
- 3 Применения сингулярного разложения
- 4 Простейшая рекомендательная система

# Построение рекомендаций фильмов

	Терминатор	Гладиатор	Рэмбо	Титаник	История любви	Спеши любить
Андрей	4	5	5	0	0	0
Иван	4	4	5	0	0	0
Сергей	5	5	4	0	0	0
Анна	0	0	0	5	5	5
Мария	0	0	0	5	5	4
Наталья	0	0	0	4	5	4

# Сингулярное разложение

$$U = \begin{pmatrix} 0. & 0.6 & -0.3 & 0. & 0. & -0.8 \\ 0. & 0.5 & -0.5 & 0. & 0. & 0.6 \\ 0. & 0.6 & 0.8 & 0. & 0. & 0.2 \\ 0.6 & 0. & 0. & -0.8 & -0.2 & 0. \\ 0.6 & 0. & 0. & 0.2 & 0.8 & 0. \\ 0.5 & 0. & 0. & 0.6 & -0.6 & 0. \end{pmatrix}$$

$$\Sigma = \text{diag}\{(14. \quad 13.7 \quad 1.2 \quad 0.6 \quad 0.6 \quad 0.5)\}$$

$$V^T = \begin{pmatrix} 0. & 0. & 0. & 0.6 & 0.6 & 0.5 \\ 0.5 & 0.6 & 0.6 & 0. & 0. & 0. \\ 0.5 & 0.3 & -0.8 & 0. & 0. & 0. \\ 0. & 0. & 0. & -0.2 & 0.8 & -0.6 \\ -0. & -0. & -0. & 0.8 & -0.2 & -0.6 \\ 0.6 & -0.8 & 0.2 & 0. & 0. & 0. \end{pmatrix}$$

## Сокращенное сингулярное разложение (K=2)

$$U_2 = \begin{pmatrix} 0. & 0.6 \\ 0. & 0.5 \\ 0. & 0.6 \\ 0.6 & 0. \\ 0.6 & 0. \\ 0.5 & 0. \end{pmatrix}$$

$$\Sigma_2 = \text{diag}\{(14. \quad 13.7)\}$$

$$V_2^T = \begin{pmatrix} 0. & 0. & 0. & 0.6 & 0.6 & 0.5 \\ 0.5 & 0.6 & 0.6 & 0. & 0. & 0. \end{pmatrix}$$

Перешли в на семантический уровень "тем"

- темы среди фильмов - боевик / мелодрама
- темы среди людей - мужчины / женщины

## Построение рекомендаций

- Требуется построить рекомендации фильмов для нового человека:

$$x = (5 \quad 0 \quad 0 \quad 0 \quad 0 \quad 0)$$

- 1 Отображаем  $x$  в пространство тем фильмов  $y$  (снижение размерности):

$$y = V_2^T x = (0 \quad 2.7)$$

- 2 Построение рекомендаций: отображаем  $y$  в исходное пространство всех оценок:

$$\hat{x} = yV_2^T = (1.5 \quad 1.6 \quad 1.6 \quad 0 \quad 0 \quad 0)$$

## Заключение

- Сингулярное разложение  $X = U\Sigma V^T$ ,  $U^T U = I$ ,  $V^T V = I$ ,  $\Sigma = \text{diag}\{\sigma_1, \dots, \sigma_R\}$  существует  $\forall X$ .
- Сокращенное сингулярное разложение порядка  $K$ 
  - решает задачу:  $X_K = \arg \min_{B: \text{rank } B \leq K} \|X - B\|_F^2$
  - извлекает тематическую структуру объектов и признаков
    - разложение по темам=главным компонентам: снижение размерности
  - сокращает
    - расходы по памяти
    - расходы на вычисления
  - позволяет построить простую рекомендательную систему
  - недостаток: отсутствие оценки=0 трактуется как оценка.